Trabalho de grupo Modelos de Regressão

Licenciatura em Ciência de Dados (2º ano)

7 de Março de 2026

Conceição Figueiredo (conceicao.figueiredo@iscte-iul.pt)
António Simões (antonio_simoes@iscte-iul.pt)

Entrega de outputs (até ao ponto 5 inclusive): 17 de abril de 2026

Deadline entrega: 28 de abril de 2026

Discussão dos trabalhos: 11, 12 e 13 de maio de 2026

Tema: Previsão dos preços em reservas em hotéis/alojamentos - desenvolver um modelo que permita estimar o preço a que os quartos são colocados no Airbnb à venda (http://insideairbnb.com/get-the-data/).

- Os docentes atribuem a cada grupo uma cidade (**ver ficheiro dos grupos e cidade**)
- Os dados podem ser importados do site **Inside Airbnb**, http://insideairbnb.com/get-the-data/
- **Apenas fazer o download** do ficheiro listings.csv da **cidade do seu grupo**.
- Cada ficheiro tem milhares de linhas e dezenas de colunas (variáveis)
- Tirar tempo para procurar o máximo de informação de contexto que permita a **compreensão** dos **dados** e do **domínio** de onde provêm.
- Neste trabalho recomenda-se usar o software R (script em RStudio ou Notebook em Jupyter Notebook, IRkernel).
- **Todos os trabalhos de grupo serão sujeitos a uma discussão oral.**

Pontos principais:

O desenvolvimento do projeto e do relatório final deve seguir a metodologia CRISP-DM.

1. Com base nos dados e a sua pesquisa sobre os dados (*Business Understanding*), definir o(s) *problema(s)/questões* que gostariam de *resolver/responder* e justificar a escolha das variáveis.
2. Fazer a limpeza dos dados.
3. Analisar gráficos e estatísticas descritivas das variáveis.
4. Analisar correlação e causalidade entre as variáveis.
5. Pré-processamento dos dados e manipulação de *features* (agrupar, juntar, eliminar, transformar as variáveis).
6. Usar algoritmos de aprendizagem supervisionada (regressão linear, regressão polinomial, interação de variáveis, regressão não-linear) sobre o seu conjunto de dados.
7. Dividir o dataset em conjuntos de treino e de teste.
8. Validar o modelo escolhido e fazer a previsão da variável dependente/alvo (sobre o conjunto de teste).
9. Avaliar a performance da previsão feita (sobre o conjunto de teste).
10. Interpretação/explicação dos resultados obtidos a partir dos dados (prós e contras).
11. **Relatório**: podem usar *dashboards*, editores de texto, ou outras ferramentas.
12. O relatório final deve ser enviado por e-mail em formato pdf. Devem ainda submeter um ficheiro zippado com o dataset final e o ficheiro com o código utilizado.
13. O **código** tem de poder ser executado AS-IS (diretamente) e deverá estar devidamente comentado.
14. Deverá incluir todas as experiências feitas, incluindo a análise e preparação de dados, modelação, e avaliação do modelo.
15. A interpretação dos resultados deve ser efetuada de forma crítica e não apenas factual.
16. O relatório tem um **limite de 25 páginas.**