

Valência

Análise de regressão dos alojamentos de Airbnb em Valência

Modelos de regressão – grupo 3



Leandro Bernardo	n.º 125293
------------------	------------

Tiago Oeber	n.º 13066
-------------	-----------

Paula Relvas	n.º 43905
--------------	-----------

Pedro Gonçalves	n.º 130668
-----------------	------------



1 BUSINESS UNDERSTANDING

1.1 ENQUADRAMENTO DO PROJETO

Este projeto tem como objetivo desenvolver um modelo de regressão supervisionada para estimar o preço por noite dos alojamentos Airbnb em Valência, Espanha, com base nas suas características estruturais, operacionais e de localização. O trabalho segue a metodologia CRISP-DM (*Cross-Industry Standard Process for Data Mining*), que organiza o processo analítico em etapas bem definidas, desde a compreensão do problema até à avaliação dos resultados.

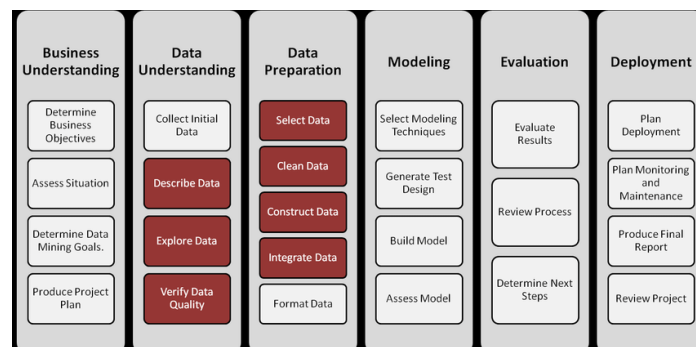


Figura 1 - CRISP-DM

A questão central que orienta este trabalho é a seguinte: Quais são os principais fatores que influenciam o preço por noite dos alojamentos Airbnb em Valência, e é possível construir um modelo de regressão supervisionada com capacidade preditiva aceitável?

Para operacionalizar esta pergunta central, foram definidas as seguintes subquestões:

1. Qual é o impacto da localização no preço do alojamento?
2. Até que ponto o tipo de alojamento explica a variação de preço?
3. As políticas de reserva têm efeito no preço?
4. A atividade passada está correlacionada com preço?
5. O perfil do anfitrião está associado a preços mais altos (oferta profissional) ou mais baixos?

Este problema tem relevância prática para diferentes intervenientes:

- Proprietários e investidores: uso do modelo para estimar o potencial de preço de um alojamento antes da sua entrada no mercado.
- Anfitriões ativos: apoio de decisões de preços e reposicionamento da oferta.
- Investigadores e decisores públicos: compreensão do funcionamento económico do mercado de alojamento local e o possível impacto da regulação.

1.2 CONTEXTO DO DOMÍNIO

Valência constitui um caso de estudo particularmente relevante para analisar a formação de preços no mercado de alojamento turístico de curta duração. Enquanto terceira maior cidade de Espanha, a cidade consolidou, em 2025, a sua posição como um dos principais destinos urbanos do país, registando 5.961.460 dormidas, 2.404.397 turistas e uma estadia média de 2,48 noites. Apesar de uma ligeira redução face a 2024, 2025 representou ainda o segundo melhor ano turístico da história recente da cidade, confirmando a forte atratividade do destino e a importância económica do setor turístico. A isto acresce o crescimento da acessibilidade aérea, com 5.931.517 passageiros em chegadas no aeroporto de Valência, o que reforça a pressão da procura turística sobre o mercado de alojamento. (Valência, 2026)

Neste contexto, o segmento de alojamento turístico de curta duração assume particular relevância. Em 2025, estimavam-se 12.608 listings ativos em Valência, refletindo um crescimento homólogo de 3%. A estrutura desta oferta era fortemente dominada pelo Airbnb, ao qual estavam associados 86% dos anúncios, enquanto 1% pertenciam à Vrbo e 13% se encontravam simultaneamente listados em ambas as plataformas. Esta concentração mostra que a intermediação digital do mercado depende fortemente de uma plataforma dominante, o que pode influenciar padrões de visibilidade, concorrência e formação de preços (Airdna, 2025).


Contudo, a análise deste mercado não pode ser dissociada do enquadramento regulatório em mudança. Em 2025, o alojamento turístico de curta duração em Valência passou a operar num contexto regulatório multiescalar, envolvendo normas europeias, nacionais, regionais e municipais. Ao nível europeu e nacional, o reforço dos mecanismos de registo, verificação e transmissão de informação pelas plataformas digitais aumentou a rastreabilidade da atividade e a capacidade de fiscalização pública. Ao nível regional e local, a exigência de compatibilidade urbanística e as restrições à expansão dos apartamentos turísticos procuraram limitar a pressão sobre o uso residencial e conter os efeitos da turistificação em determinados bairros. Do ponto de vista analítico, isto significa que a oferta observada nas plataformas não reflete apenas a dinâmica económica do mercado, mas também processos institucionais de formalização, controlo e eventual remoção de unidades irregulares (UE, 2025) (Espanha, 2024).

É neste enquadramento que se justifica a aplicação de uma abordagem analítica ao mercado de alojamento turístico de curta duração em Valência. O problema de negócio consiste em compreender de que forma as características dos alojamentos influenciam o preço praticado num mercado competitivo, digitalizado e regulado, onde coexistem pressão turística, heterogeneidade da oferta e intervenção pública crescente. Assim, a modelação dos preços permite não apenas identificar os principais determinantes económicos do valor dos alojamentos, mas também produzir conhecimento útil para proprietários, plataformas e decisores públicos interessados em compreender o funcionamento deste mercado.

O dataset utilizado, listings.csv, reúne informação sobre a oferta de alojamento turístico de curta duração em Valência entre 23 de setembro de 2024 e 23 de setembro de 2025, com periodicidade quadrimestral vindo do insider Airbnb . Este horizonte temporal é particularmente relevante, pois capta um período de elevada atividade turística e simultaneamente de transformação regulatória, permitindo analisar a formação de preços num contexto realista e dinâmico.

2 DATA UNDERSTANDING

2.1 DESCRIÇÃO DOS DADOS



O dataset em estudo contém 7844 observações, cada uma representando uma listagem de alojamento airbnb. Existem 18 variáveis no dataset, cada variável representa uma entidade (alojamento ou anfitrião), 3 variáveis representam o anfitrião, enquanto 15 representam o alojamento, como mostra a **Erro! A origem da referência não foi encontrada..**

Variável	Descrição	Entidade	Intervalo de valores
id	Identificador do alojamento	Alojamento	[744849560721863587, 744900901922925696, ...]
name	Nome do alojamento	Alojamento	[Apartamento cerca centro., Apartamento cerca de la Marina, Apartamento cerca de la playa, ...]
host_id	Identificador do anfitrião do alojamento	Anfitrião	[594561372, 594592918, 594772159, 595121614, ...]
host_name	Nome do anfitrião	Anfitrião	[Kate, Prado, Praveen, Premium Flats, Promociones Y Construcciones, ...]
neighbourhood_group	Grupo de bairros	Alojamento	[ALGIROS, BENICALAP, BENIMACLET, CAMINS AL GRAU, ...]
neighbourhood	Bairro onde o alojamento se localiza	Alojamento	[AIORA, ALBORS, ARRANCAPINS, BENICALAP, ...]
latitude	Coordenada geográfica	Alojamento	[39.2799863 ; 39.54579]
longitude	Coordenada geográfica	Alojamento	[-0.42584 ; -0.27628]
room_type	Tipo de alojamento	Alojamento	[Entire home/apt, Hotel room, Private room, Shared room]
price	Preço por noite(euros)	Alojamento	[8 ; 40000]
minimum_nights	Número mínimo de noites por reserva	Alojamento	[1 ; 366]
number_of_reviews	Número total de avaliações	Alojamento	[0 ; 935]
last_review	Data da última avaliação	Alojamento	2013-07-02 - 2025-09-23
reviews_per_month	Número médio de avaliações por mês	Alojamento	[0.01 ; 37.71]
calculated_host_listings_count	Número de alojamentos do mesmo anfitrião	Anfitrião	[1; 103]

availability_365	Número de dias disponíveis ao longo do ano	Alojamento	[0 ; 365]
number_of_reviews_ltm	Número de avaliações nos últimos 12 meses	Alojamento	[0 ; 367]
license	Número de licença do alojamento	Alojamento	] ESFCNT0 ... 0460610002006560 ... 05, ESFCNT0 ... 0460610002310870...07, ... [

Tabela 1 - legenda dos dados

O dataset tem dados de natureza cross-sectional com uma variável temporal (last_review), é preciso também sublinhar que o preço está em euros, a tipologia das variáveis pode ser vista na **Erro! A origem da referência não foi encontrada..**

Variáveis qualitativas	
Nominais	name, host_name, neighbourhood_group, neighbourhood, license, id, host_id, room_type
Variáveis quantitativas	
discretas	number_of_reviews_ltm, number_of_reviews, minimum_nights, calculated_host_listings_count
contínuas	latitude, longitude, price, reviews_per_months, last_review* ¹

Tabela 2 - Tipologia das variáveis

O identificador do alojamento (id) e o identificador do anfitrião (host_id) não serão utilizados na análise, por se tratar de variáveis meramente identificativas, sem utilidade analítica direta para a modelação.

2.1.1 DESCRIÇÃO DOS DADOS QUANTITATIVOS

A variável number_of_reviews (número total de avaliações) apresenta uma média de 51,636 e uma mediana de 16, o que indica que a maioria dos alojamentos regista um número relativamente baixo de avaliações, não obstante a existência de valores bastante elevados (máximo de 935).

De forma semelhante, a variável number_of_reviews_ltm (número médio de avaliações por mês) apresenta uma média de 13,353 e uma mediana de 6 avaliações mensais, evidenciando uma atividade recente mais reduzida comparativamente ao total acumulado de avaliações (máximo de 367).

A variável minimum_nights (número mínimo de noites) apresenta uma média de 6,554 e uma mediana de 2, sugerindo que a maioria dos alojamentos privilegia estadias curtas, ainda que existam casos com exigências significativamente superiores (máximo de 366 noites).

¹ last_review é uma variável temporal, representa

Por fim, a variável `calculated_host_listings_count` (número de listagens por anfitrião) apresenta uma média de 12,325 e uma mediana de 3, indicando que a generalidade dos anfitriões gere um número reduzido de alojamentos, coexistindo, no entanto, com perfis de maior escala.

2.2 EXPLORAÇÃO DOS DADOS

As distribuições confirmam forte assimetria positiva no preço (1 328.5), em `minimum_nights` (228,1) e nas variáveis de reviews, o que afeta diretamente a escolha dos modelos: uma regressão linear sobre `price` fica demasiado exposta a valores extremos, enquanto a transformação logarítmica reduz a influência relativa dos preços muito elevados. (ver **Tabela 10** e **Tabela 11**) (ver **Figura 1**)




Figura 1 - Distribuições das variáveis quantitativas

2.2.1 OFERTA DO MERCADO

A oferta concentra-se em POBLATS MARITIMS (zona marítima) e CIUTAT VELLA (centro histórico), que juntos representam mais de um terço do dataset. (ver Figura 2)




Figura 2 - Top 10 distritos por número de listagens

Quanto à estrutura de mercado, os 3 464 anfitriões únicos gerem em média 2,3 listagens cada, mas a distribuição é muito desigual: apenas 91 anfitriões profissionais (2,6% do total, com 10 ou mais listagens cada) controlam 27,1% do dataset, sendo o maior deles SingularStays com 103 listagens. Esta concentração

poderá introduzir efeitos de cluster na modelação, uma vez que as listagens de um mesmo anfitrião profissional tendem a partilhar características semelhantes (política de preços, estilo de descrição, localização).

Critério	Anfitriões	% Anfitriões	Listagens	% Dataset
≥ 10 listagens	91	2,6%	2 126	27,1%
≥ 5 listagens	281	8,1%	3 323	42,4%

Tabela 3 - Concentração de listagens por anfitriões profissionais

O mercado é dominado por "Entire home/apt" (73.7%), seguido de "Private room" (26.0%). As categorias "Hotel room" (0.2%) e "Shared room" (0.1%) são residuais, juntas representam apenas 26 observações, o que poderá justificar o seu agrupamento numa única categoria ("Outro") para evitar instabilidade nos coeficientes durante a modelação.

Distrito	N	%
POBLATS MARITIMS	1 471	18,8%
CIUTAT VELLA	1 284	16,4%
QUATRE CARRERES	814	10,4%
CAMINS AL GRAU	729	9,3%
L'EIXAMPLE	686	8,7%
(restantes 14)	2 860	36,5%

Tabela 4 - Top 5 distritos (neighbourhood_group)

A oferta concentra-se na zona marítima e no centro histórico: os dois maiores distritos, POBLATS MARITIMS (18.8%) e CIUTAT VELLA (16.4%), representam mais de um terço do dataset. A um nível mais fino, os 85 bairros (neighbourhood) apresentam distribuição igualmente concentrada, com CABANYAL-CANYAMELAR (9.6%), RUSSAFA (7.2%) e AIORA (4.4%) no topo; no extremo oposto, 8 bairros têm apenas 1-2 observações, o que poderá exigir agrupamento para evitar sobreajustamento na modelação.

2.3 VERIFICAR A QUALIDADE DOS DADOS

2.3.1 VALORES OMISSOS

Existem 3940 observações com pelo menos 1 valor omissos, o que representa 50% do dataset, a variável com maior número omissos é a licença (license) com 3311 omissos (41%), esta variável é o identificador emitido por entidades públicas (normalmente municipais ou regionais) que indica que o alojamento está registado oficialmente, cumpre requisitos legais, pode operar como alojamento local (short-term rental).

Colunas	# Valores Omissos	Valores omissos %
host_name	6	0,08
price	865	11,03

last_review	977	12,46
reviews_per_month	977	12,46
license	3311	42,21
Total de observações com >1 valor omisso	3940	50,23

Tabela 6 - Número de valores omissos por coluna

Visto que, por agora, vão ser estas as colunas que nos vão causar problemas, nós decidimos começar por estudá-las. A tabela abaixo contém uma análise estatística delas.

As colunas numéricas foram analisadas a partir da média, desvio padrão e dos quartis, já as variáveis categóricas foram avaliadas com a moda, a quantidade de vezes que a moda existe na base de dados (Frequência) e com a quantidade de valores únicos.

Colunas	price	reviews_per_month
Média	164,11	1,70
Desvio padrão	732,64	1,67
Mínimo	8	0,01
1º Quartil	71	0,47
Mediana	102	1,17
3º Quartil	140	2,49
Máximo	40 000	37,71

Tabela 7 – Estatísticas descritivas das variáveis numéricas com valores em falta

Colunas	host_name	last_review	license
Valores únicos	1764	750	3988
Moda	Marta	2025-09-21	VT-54221-V
Frequência	124	276	19

Tabela 8 – Estatísticas descritivas das variáveis categóricas com valores em falta

Existe uma diferença na distribuição dos preços entre os alojamentos que têm licença e os que não têm licença. Os alojamentos com licença tendem a apresentar preços mais elevados e uma distribuição mais concentrada na zona central, mas com caudas mais pesadas, o que indica a presença de valores extremos muito elevados. Neste grupo, a média é de 196,35 euros, enquanto a mediana é de 112 euros, o que mostra uma assimetria positiva acentuada. O desvio-padrão é também muito mais elevado, situando-se em 925,02, o que revela uma dispersão bastante superior. O valor mínimo é de 16 euros e o valor máximo atinge 40 000 euros, confirmando a existência de outliers muito expressivos.

Os alojamentos sem licença tendem a apresentar preços mais baixos e uma dispersão inferior. Neste grupo, a média é de 116,40 euros e a mediana é de 75 euros, o que também indica assimetria positiva, mas menos intensa do que nos alojamentos com licença. O desvio-padrão é de 247,14, bastante inferior ao do grupo

com licença, mostrando uma menor variabilidade dos preços. O valor mínimo é de 8 euros e o valor máximo é de 3 000 euros, o que sugere igualmente a presença de valores extremos, embora muito menos severos.

No gráfico **Figura 3** pode-se observar a diferença entre as distribuições dos alojamentos com e sem licença: com licença continua ligeiramente deslocada para a direita, a curva dos alojamentos com licença apresenta um pico mais acentuado, enquanto a curva dos alojamentos sem licença surge mais espalhada na zona central.




Figura 3 - Distribuição dos preços, divididos pela licença (se existe ou não)




Figura 4 - Boxplots de variáveis com valores extremos

Os boxplots mostram que os outliers são numerosos e não podem ser tratados como simples erro aleatório.

Atributo	N	Outliers
price	6 979	419
minimum_nights	7 844	810
number_of_reviews	7 844	863
number_of_reviews_ltm	7 844	359
reviews_per_month	6 867	201
calc_host_listings_count	7 844	1 182
availability_365	7 844	0

Tabela 3 - Contagem de outliers por variável (método IQR)

2.4 INFORMAÇÃO INVÁLIDA E DUPLICADOS

O dataset não contém duplicados exatos nem IDs repetidos, as 7 844 listagens são todas distintas e cada uma tem um identificador único. A verificação de informação inválida revelou um dataset globalmente limpo.

2.5 CORRELAÇÃO E CAUSALIDADE

A análise de causalidade permanece limitada. O desenho é observacional e cross-sectional; por isso, os coeficientes e importâncias indicam associação condicional, não efeitos causais. Uma variável como `license_exists` pode estar associada a preços mais altos por refletir formalização, localização ou qualidade não observada. Reviews também podem ser simultaneamente causa e consequência de políticas de preço.

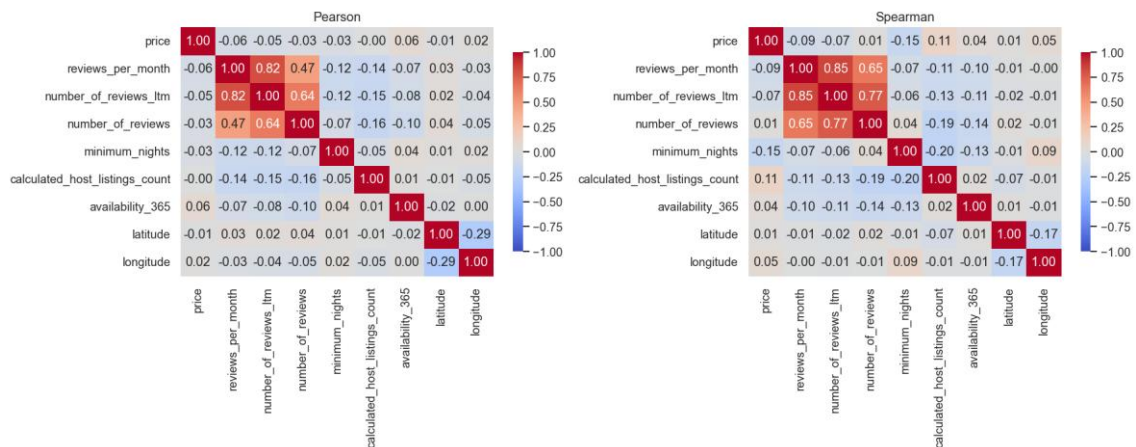


Figure 5- Correlações entre variáveis numéricas

As correlações simples com `price` são modestas, o que antecipa a limitação dos modelos lineares. Ainda assim, uma correlação bivariada fraca não elimina utilidade preditiva: variáveis podem tornar-se relevantes em conjunto, após transformação logarítmica, codificação de categorias e controlo de outros fatores.

Os modelos estimam associações condicionais entre variáveis observáveis e preço. Não permitem afirmar que alterar uma variável causaria diretamente uma alteração no preço, porque existem fatores omitidos, como dimensão, qualidade, comodidades, reputação detalhada e localização microgeográfica. A análise seguinte deve, por isso, ser lida como evidência associativa e não causal.

3 DATA PREPARATION

3.1 LIMPEZA, TRANSFORMAÇÃO E CODIFICAÇÃO

Foram removidas 865 observações sem `price`, porque a variável alvo é indispensável para o treino supervisionado. Após esta remoção, o dataset passou de 7844 para 6979 observações válidas para análise com preço. A variável `reviews_per_month` foi preenchida com zero quando estava ausente, assumindo-se que a ausência de valor corresponde a alojamentos sem reviews registadas. Depois desta limpeza inicial, os principais valores omissos restantes concentravam-se em `license`, com 2814 valores ausentes, correspondentes a 40,32% das observações, e em `last_review`, com 819 valores ausentes, correspondentes

a 11,74%. A variável `host_name` foi preenchida com `Unknown` apenas para consistência descritiva, não sendo usada como preditor na modelação.

A variável `license` foi transformada em `license_exists`, assumindo o valor 1 quando o alojamento tinha licença visível e 0 quando não tinha. Esta transformação evitou usar códigos administrativos como categorias diretas e permitiu representar a licença como uma variável binária interpretável. Também foi criada a variável `has_reviews`, igual a 1 quando o alojamento tinha pelo menos uma review e 0 caso contrário. A variável `professional` foi construída a partir de `calculated_host_listings_count`, assumindo o valor 1 quando o anfitrião geria 10 ou mais listagens e 0 quando geria menos de 10.

A variável `minimum_nights` foi transformada em `log_minimum_nights`, porque apresentava forte assimetria positiva.

Esta transformação reduz a influência de valores extremos e representa melhor a diferença entre estadias mínimas curtas e muito longas. Por exemplo, a diferença entre 1 e 2 noites é tratada como mais relevante do que a diferença entre 101 e 102 noites, o que é adequado quando a variável tem cauda longa.

As variáveis categóricas foram codificadas por One-Hot Encoding. No caso de `room_type`, a categoria `Entire home/apt` foi omitida e usada como categoria de referência. Depois da remoção de observações sem `price`, a distribuição usada para estratificação era: 5236 alojamentos `Entire home/apt`, 1720 `Private room`, 13 `Hotel room` e 10 `Shared room`. Assim, foram criadas as variáveis `room_type_Private room`, `room_type_Shared room` e `room_type_Hotel room`, que comparam cada categoria com os alojamentos inteiros.

3.2 CLUSTERING

A latitude e a longitude foram agregadas em três clusters geográficos através de K-Means. A escolha de $k = 3$ foi apoiada pelo silhouette score: $k = 3$ obteve 0,5166, valor superior ao de $k = 2$, que obteve 0,4986, e aos restantes valores testados entre $k = 4$ e $k = 9$. Durante o processo de criação de dummies para estes clusters, o cluster C0 (Cluster litoral urbano) foi deixado de fora como variável de referência. Os nomes dados aos clusters foram baseados nas suas localizações, numa análise aeroespacial, como pode ser observado




Figura 7, Figura 8)

C0 = Cluster litoral urbano

C1 = Cluster centro histórico-turístico

C2 = Cluster litoral sul premium

Os três clusters apresentaram diferenças relevantes no preço: o cluster centro histórico-turístico reuniu 4325 alojamentos, com preço mediano de 102€ e média de 139,1€; o cluster litoral urbano reuniu 2558 alojamentos, com mediana de 101€ e média de 184,6€; e o cluster litoral sul premium reuniu apenas 96 alojamentos, mas com mediana de 135,5€ e média de 744,4€. A diferença mostra que a localização contém informação preditiva relevante.

A comparação adicional com bairros agregados mostra que a localização urbana real contém informação preditiva relevante. Ainda assim, no modelo principal manteve-se K-Means por parcimónia e estabilidade; para uma versão orientada sobretudo à previsão, bairros agregados são uma alternativa promissora por preservarem significado urbano e turístico.

3.3 MULTICOLINERIEDADE E OUTLIERS MULTI-VARIADOS

Inicialmente foram considerados 15 preditores candidatos para a modelação: `reviews_per_month`, `number_of_reviews_ltm`, `number_of_reviews`, `log_minimum_nights`, `calculated_host_listings_count`, `availability_rate`, `days_since_last_review`, `license_exists`, `has_reviews`, `professional`, `room_type_Private room`, `room_type_Shared room`, `room_type_Hotel room`, `Cluster_centro_histórico-turístico` e `Cluster_litoral_sul_premium`. O diagnóstico de multicolinearidade mostrou VIF muito elevado em `days_since_last_review`, com $VIF = 32,945$, e em `has_reviews`, com $VIF = 31,486$. Como `days_since_last_review` estava fortemente relacionado com `has_reviews`, foi removida. Após essa remoção, o maior VIF passou a ser 4,401, em `number_of_reviews_ltm`, ficando abaixo do limiar de 5 usado no código.

Por fim, foram diagnosticadas observações influentes com a distância de Cook no modelo linear auxiliar com `log_price`. O limiar usado foi $D_i > \frac{4}{n}$, o que corresponde a 0,000573. Foram removidas 279 observações influentes, ficando 6700 observações finais para modelação e 14 preditores finais como mostra a **Tabela 4**. Esta remoção não foi uma forma de reduzir observações com influência excessiva sobre os modelos lineares, nos modelos de árvores esta decisão é menos importante, mas mantém a comparação entre famílias de modelos mais coerente.

Conjunto base de preditores (X_base)

`reviews_per_month`, `number_of_reviews_ltm`, `number_of_reviews`,
`log_minimum_nights`, `calculated_host_listings_count`, `availability_rate`, `license_exists`,

has_reviews, profissional, room_type_Private_room,
room_type_Shared_room, room_type_Hotel_room, location_cluster_1, location_cluster_2

Tabela 4 - conjunto base dos preditores

Foi aplicado logaritmo às features nos modelos auxiliares a realizar os pressupostos:

X_logfeat = X_base, mas com log1p aplicado a:

number_of_reviews, reviews_per_month, number_of_reviews_ltm,
calculated_host_listings_count

4 MODELAÇÃO

4.1 METODOLOGIA DE SELEÇÃO DO MODELO

1. Definição de price como variável dependente e seleção de 14 preditores candidatos após limpeza e VIF.
2. Tratamento de valores omissos e remoção de observações influentes pela distância de Cook.
3. Codificação One-Hot das variáveis categóricas e criação de features derivadas.
4. Normalização das variáveis numéricas nos modelos sensíveis à escala: regressões regularizadas e SVR.
5. Divisão treino/teste 80/20, estratificada por quantis de log(price), para preservar a distribuição do alvo.
6. Validação cruzada k-fold com k=5 no conjunto de treino.
7. Otimização de hiperparâmetros com GridSearchCV ou RandomizedSearchCV, usando RMSE como critério de refit.
8. Comparação final no teste com MAE, RMSE, MedAE, MAPE, WAPE, R² e erro máximo absoluto.
9. Escolha do modelo considerando desempenho preditivo, robustez treino-CV-teste e interpretabilidade.

4.2 MODELOS UTILIZADOS

A tabela seguinte resume os modelos, especificações e correções metodológicas testadas ao longo da modelação. A sua inclusão não teve apenas o objetivo de acumular algoritmos, mas sim comparar abordagens com funções diferentes: modelos simples para estabelecer uma referência, modelos lineares para interpretação, modelos regularizados para lidar com instabilidade e multicolinearidade, modelos robustos para avaliar a sensibilidade a outliers e heterocedasticidade, e modelos não lineares para verificar se relações mais complexas melhoravam a previsão.

Esta organização é importante porque o problema de previsão de preços no Airbnb não apresenta uma relação perfeitamente linear entre as variáveis disponíveis e o preço. A variável price é assimétrica, contém valores extremos e depende de fatores que podem interagir entre si, como tipo de alojamento, localização, número de reviews, disponibilidade e perfil do anfitrião. Por isso, começou-se por modelos

clássicos e interpretáveis, como a regressão linear, Ridge, Lasso e Elastic Net, e só depois foram testados modelos mais flexíveis, como Random Forest, HistGradientBoosting e SVR.

Os modelos avançados foram incluídos para avaliar se havia ganho preditivo face aos modelos clássicos, não para substituir automaticamente a interpretação estatística. Assim, a comparação entre modelos foi feita considerando simultaneamente erro preditivo, estabilidade entre treino, validação cruzada e teste, risco de overfitting e interpretabilidade. Desta forma, os modelos lineares ajudam a compreender associações entre variáveis e preço, enquanto os modelos não lineares testam se existe melhoria prática na capacidade de previsão.

Modelo / componente	Variáveis utilizadas	Justificação
Baseline média	Apenas price no conjunto de treino.	Modelo nulo que prevê sempre a média do treino; referência mínima para avaliar ganho preditivo.
Linear raw y	X_base com alvo price.	Regressão linear sobre price; mostra o impacto da assimetria e dos outliers.
Linear log(y)	X_base com alvo log(price).	Regressão linear com log(price); reduz assimetria do alvo e permite interpretação percentual.
Modelo com dummies One-Hot	room_type_Private_room, room_type_Shared_room, room_type_Hotel_room, C1, C2.	Especificação das variáveis categóricas através de categorias de referência.
Bairros agregados	X_bairros, ou seja, X_base sem clusters e com dummies de bairros agregados.	Especificação geográfica alternativa aos clusters K-Means; aumenta a dimensionalidade, mas melhora a interpretação espacial.
Ridge	X_base com alvo log(price).	Regressão linear regularizada com penalização L2; melhora estabilidade dos coeficientes.
Lasso	X_base com alvo log(price).	Regressão linear regularizada com penalização L1; pode eliminar variáveis.
Lasso 1-SE	room_type_Private_room, log_minimum_nights, reviews_per_month.	Variante mais parcimoniosa do Lasso; privilegia simplicidade e seleção de variáveis em troca de algum desempenho.
Elastic Net	X_base com alvo log(price).	Combina Ridge e Lasso; junta estabilidade dos coeficientes com possível seleção de variáveis.
Weighted Least Squares	X_logfeat com alvo sqrt(price).	Regressão linear ponderada para reduzir problemas de heterocedasticidade.
Erros-padrão robustos HC3	Modelo linear interpretativo com X_base e alvo log(price).	Correção inferencial para heterocedasticidade; não altera previsões, apenas a leitura estatística dos coeficientes.
QuantileRegressor mediano	X_logfeat com alvo sqrt(price).	Modelo linear robusto que estima a mediana condicional; menos sensível a assimetria e valores extremos.
HuberRegressor	X_logfeat com alvo sqrt(price).	Regressão robusta que reduz a influência de resíduos extremos.
RANSACRegressor	X_logfeat com alvo sqrt(price).	Regressão robusta baseada em subconjuntos e inliers; usada como diagnóstico de sensibilidade a outliers.
Polinomial grau 2	X_base transformado por PolynomialFeatures(degree=2), com alvo log(price).	Introduz termos quadráticos e produtos de grau 2; testa curvatura e não linearidade.
Interações grau 2	X_base transformado por PolynomialFeatures(interaction_only=True), com alvo log(price).	Testa efeitos condicionais entre variáveis; o efeito de uma variável pode depender de outra.

Support Vector Regression (SVR RBF)	X_base normalizado, com alvo log(price).	Modelo kernelizado, sensível à escala, capaz de captar relações não lineares.
Random Forest regularizado	X_base com alvo log(price).	Variante constrangida do Random Forest, com profundidade e folhas mínimas fixas para reduzir overfitting.
Random Forest	X_base com alvo log(price).	Modelo de árvores em ensemble; capta relações não lineares e interações automaticamente.
HistGradientBoosting	X_base com alvo log(price).	Modelo boosting sequencial, não linear e flexível; cada árvore corrige erros das anteriores.

Tabela 5 – Modelos utilizados no trabalho

4.3 OTIMIZAÇÃO DE HIPERPARÂMETROS

A otimização foi realizada apenas no conjunto de treino, para evitar fuga de informação do teste. Nos modelos lineares sem Hiper-parâmetros relevantes, como a regressão linear múltipla, a validação cruzada foi usada para estimar estabilidade fora da amostra. Nos modelos regularizados, o principal hiperparâmetro foi a força de penalização alpha. No Elastic Net, foi também ajustado l1_ratio, que determina a mistura entre penalização L1 e L2.

Nos modelos não lineares, a pesquisa foi deliberadamente moderada para manter viabilidade computacional e reduzir risco de sobreajustamento por excesso de procura. No Random Forest foram testados número de árvores, profundidade máxima, número mínimo de observações por folha e proporção de variáveis usadas em cada divisão. No HistGradientBoosting foram testados learning_rate, número de iterações, regularização L2 e número máximo de folhas. No SVR foram testados C, epsilon e gamma.

O critério de refit foi o RMSE em validação cruzada, porque penaliza fortemente erros grandes, relevantes num problema de preço. No entanto, a decisão final não se baseou exclusivamente no RMSE: MAE, MedAE, MAPE, WAPE, R^2 , erro máximo absoluto e diferença entre treino, validação e teste foram analisados em conjunto.

4.4 MODELOS LINEARES E REGULARIZADOS

Nos modelos lineares e regularizados foram avaliados os principais pressupostos da regressão: relação entre resíduos e valores ajustados, homocedasticidade pelo teste de Breusch-Pagan, normalidade dos resíduos pelos testes de Shapiro-Wilk e Jarque-Bera, independência pelo teste de Durbin-Watson, multicolinearidade pelo VIF e observações influentes pela distância de Cook.

O diagnóstico mostrou que a linearidade residual era aceitável, mas a homocedasticidade não foi cumprida nos modelos lineares e regularizados. Por isso, a análise não se limitou a identificar o problema: foram testadas transformações da variável dependente, transformações logarítmicas nos preditores mais assimétricos, Weighted Least Squares e modelos robustos.

A multicolinearidade ficou controlada depois da remoção das variáveis com VIF elevado, ficando o VIF máximo final em **4,30**. A remoção por distância de Cook também reduziu o peso das observações mais influentes, embora ainda tenham permanecido **207 observações no treino** acima do limiar $4/n$, cerca de **3,86%**. Por isso, este problema foi considerado parcialmente mitigado, mas não totalmente eliminado.

A importância da distância de Cook ficou clara na regressão linear com $\log(\text{price})$: sem essa filtragem, o RMSE de teste era **581,71€**; depois da remoção das observações influentes, caiu para **55,99€**. Esta diferença não significa que todos os alojamentos extremos sejam erros, mas mostra que os modelos lineares são muito sensíveis a casos atípicos. Por isso, a heterocedasticidade e a robustez dos modelos foram analisadas numa etapa própria, separando desempenho preditivo, estabilidade dos resíduos e utilidade interpretativa.

4.5 CORREÇÃO DA HETEROCEDASTICIDADE

A heterocedasticidade foi identificada pelo teste de Breusch-Pagan e também apareceu nos gráficos de resíduos (ver Figura 9). Em vez de os resíduos terem uma dispersão semelhante ao longo das previsões, observou-se uma variação desigual: alguns intervalos de preço apresentavam erros mais espalhados do que outros. Isto é relevante porque, nos modelos lineares, a variância não constante dos resíduos torna a inferência menos fiável. Nos modelos lineares iniciais, o problema foi claro. A regressão linear sobre price teve $p = 0,024$ no teste de Breusch-Pagan, enquanto a regressão com $\log(\text{price})$, a regressão polinomial, o modelo com interações, Ridge, Lasso e Elastic Net tiveram $p < 0,001$. Como estes valores ficam abaixo de 0,05, há evidência estatística de heterocedasticidade.

Foram então testadas várias formas de reduzir o problema. Primeiro, compararam-se diferentes transformações da variável dependente: price, $\log(\text{price})$, $\log1p(\text{price})$ e $\sqrt{\text{price}}$. A transformação logarítmica ajudou a reduzir a assimetria do preço e melhorou algumas métricas, como MAE e WAPE, mas não resolveu sozinha a heterocedasticidade. A melhoria mais clara surgiu quando se transformaram também os preditores mais assimétricos com $\log1p$ ($\log1p(x) = \log(1 + x)$), nomeadamente number_of_reviews, reviews_per_month, number_of_reviews_ltm e calculated_host_listings_count. Estas variáveis têm distribuições muito concentradas em valores baixos, mas com alguns valores muito elevados, por isso a transformação ajuda a reduzir o peso da cauda longa. Depois foram testadas correções adicionais. O Weighted Least Squares atribuiu menor peso às observações com maior variância estimada dos erros, procurando impedir que estas dominassem o ajustamento do modelo – $w_i = \frac{1}{\sigma_i^2}$.

$$\text{Min } \sum w_i (y_i - \hat{y}_i)^2.$$

Também foram testados modelos robustos, como HuberRegressor, RANSACRegressor e QuantileRegressor mediano. Estes modelos foram usados para perceber se os resultados lineares dependiam demasiado de observações com resíduos muito elevados. Além disso, foram usados erros-padrão robustos HC3, mas apenas como correção inferencial: o HC3 não altera previsões nem resíduos, apenas torna a leitura dos coeficientes mais cautelosa perante heterocedasticidade.

Os resultados mostram que algumas especificações corrigiram o problema de forma aceitável. A regressão linear com preditores transformados por $\log1p$ e alvo price obteve $p = 0,0967$ no Breusch-Pagan. A versão com alvo $\sqrt{\text{price}}$ obteve $p = 0,1768$, e o WLS com $\sqrt{\text{price}}$ obteve $p = 0,1640$. Como estes valores ficam acima de 0,05, estas versões não apresentaram evidência estatística forte de heterocedasticidade.

Assim, para diagnóstico residual, a melhor opção linear foi a especificação com preditores assimétricos

transformados por $\log p$ e alvo $\sqrt{\text{price}}$, com ou sem WLS. Já a regressão com $\log(\text{price})$ continua útil para interpretação económica, porque permite ler os coeficientes de forma aproximada em percentagem, mas deve ser interpretada com cautela e acompanhada por erros-padrão robustos HC3.

Modelo	Transformação	Método	BP p-value	Homoc ed.	RMS E	MAE	R ²	WAPE	Decisão
M1 - Linear múltipla raw y	price	OLS inicial	0,0240	Não cumpre	55,29	36,22	0,288	32,75	Não corrigido
M2 - Linear múltipla log(y)	log(price)	OLS inicial	<0,001	Não cumpre	55,99	34,16	0,270	30,88	Mantido para interpretação cautelosa
RANSACRegressor	$\sqrt{\text{price}}$	Regressão robusta	0,2407	Cumpr e	56,10	33,54	0,267	30,33	Corrigido de forma aceitável
HuberRegressor	$\sqrt{\text{price}}$	Regressão robusta	0,2206	Cumpr e	56,39	33,46	0,259	30,25	Corrigido de forma aceitável
QuantileRegressor_mediana	$\sqrt{\text{price}}$	Regressão robusta	0,2106	Cumpr e	56,82	33,39	0,248	30,19	Corrigido de forma aceitável
Regressão linear	$\sqrt{\text{price}}$	OLS transformado	0,1768	Cumpr e	55,33	34,36	0,287	31,07	Corrigido de forma aceitável
Regressão linear ponderada	$\sqrt{\text{price}}$	Weighted Least Squares	0,1640	Cumpr e	55,37	34,41	0,286	31,12	Corrigido de forma aceitável
Regressão linear	price	OLS transformado	0,0967	Cumpr e	55,20	35,75	0,290	32,33	Corrigido de forma aceitável
Regressão linear	price	OLS transformado	0,0240	Não cumpre	55,27	36,19	0,288	32,73	Melhorou parcialmente
Regressão linear	$\sqrt{\text{price}}$	OLS transformado	0,0139	Não cumpre	55,37	34,77	0,286	31,44	Melhorou parcialmente

Tabela 6 - Comparação das correções da heterocedasticidade nos modelos lineares

4.6 MODELOS AVANÇADOS NÃO LINEARES

Os pressupostos clássicos da regressão linear, como linearidade, homocedasticidade, normalidade dos resíduos e ausência de multicolinearidade problemática, são especialmente relevantes para modelos lineares quando se pretende fazer inferência sobre coeficientes. Nos modelos avançados, como Random Forest, HistGradientBoosting e SVR RBF, estes pressupostos não são exigidos da mesma forma, porque os modelos não estimam uma relação linear paramétrica entre as variáveis explicativas e a variável dependente. Nestes casos, a avaliação deve centrar-se sobretudo no desempenho preditivo, nos resíduos, na validação cruzada, na calibração, no risco de overfitting e na interpretabilidade por importância das variáveis, PDP ou SHAP.

5 AVALIAÇÃO DE RESULTADOS

5.1 COMPARAÇÃO E INTERPRETAÇÃO DOS MODELOS

Como a tabela 7 mostra, A baseline pela média tem R² aproximadamente nulo, como esperado, e serve apenas para quantificar o ganho mínimo exigido a qualquer modelo útil. A regressão linear múltipla sobre price reduz substancialmente o erro face à baseline, mas continua muito sensível à escala do alvo. A versão com $\log(\text{price})$ apresenta pior RMSE absoluto do que a linear raw em

alguns indicadores, mas melhora a leitura percentual e torna os coeficientes mais compatíveis com a natureza multiplicativa dos preços.

A regressão polinomial e o modelo com interações melhoram pouco face à regressão linear logarítmica. Isto sugere que há alguma não-linearidade, mas que os termos quadráticos e interações globais não captam toda a complexidade do mercado. A melhoria substancial surge apenas quando os modelos conseguem particionar o espaço de preditores de forma local, como acontece nos métodos de árvores.

Ridge, Lasso e Elastic Net têm desempenho praticamente idêntico ao modelo linear logarítmico. Este resultado indica que a multicolinearidade residual não é o principal obstáculo à previsão depois da remoção por VIF, a regularização é ainda assim útil por estabilizar coeficientes e, no caso do Lasso, por permitir estudar parcimónia.

A interpretação dos coeficientes depende da forma funcional do modelo. Num modelo linear em níveis, em que tanto a variável dependente como a variável explicativa estão expressas na escala original, o coeficiente representa uma variação absoluta: um aumento de uma unidade na variável explicativa está associado a uma variação média de β unidades na variável dependente, mantendo constantes as restantes variáveis.

Quando a variável dependente está transformada em logaritmo, como acontece nos modelos com $\log(\text{price})$, os coeficientes passam a ter uma interpretação aproximada em termos percentuais. Assim, um aumento de uma unidade numa variável explicativa está associado a uma variação aproximada de $100\beta\%$ no preço, mantendo constantes as restantes variáveis. Quando se pretende uma leitura percentual mais exata, pode usar-se a transformação $\exp(\beta) - 1$.

Quando tanto a variável dependente como uma variável explicativa contínua estão em logaritmo, o coeficiente pode ser interpretado como uma elasticidade. Neste caso, um aumento de 1% na variável explicativa está associado a uma variação aproximada de $\beta\%$ no preço, mantendo constantes as restantes variáveis.

No caso das variáveis categóricas em modelos com $\log(\text{price})$, os coeficientes devem ser interpretados relativamente à categoria de referência. Um coeficiente positivo indica que essa categoria está associada a preços superiores aos da categoria de referência, enquanto um coeficiente negativo indica preços inferiores. A interpretação percentual exacta pode ser obtida através de $\exp(\beta) - 1$, multiplicando o resultado por 100.

Estas interpretações devem ser entendidas como associações condicionais, e não como efeitos causais. O estudo é observacional e existem variáveis relevantes que não estão presentes no dataset, pelo que não é possível afirmar que a alteração direta de uma variável causaria necessariamente uma alteração no preço.

O SVR RBF melhora face aos modelos lineares, mas não alcança os modelos de árvores. Isto é plausível num dataset com dummies, distribuições assimétricas e interações locais: o kernel RBF capta alguma não-linearidade, mas é sensível à escala, à escolha de $C/\text{epsilon}/\text{gamma}$ e à densidade local dos pontos. O seu ganho não justifica, neste caso, a perda de interpretabilidade e o custo computacional adicional.

Random Forest e HistGradientBoosting são os modelos com melhor desempenho. O primeiro vence em RMSE de teste, mas apresenta uma diferença grande entre treino e teste, sinal de elevada flexibilidade. O segundo fica praticamente empatado no teste e apresenta menor hiato treino-teste, o que o torna preferível quando o objetivo é equilíbrio entre desempenho e robustez.

A versão regularizada do Random Forest (max_depth=10 e min_samples_leaf=5) confirma o trade-off esperado: o RMSE de teste piora de 49.995€ para 51.598€, mas o hiato treino-teste cai de 27.835€ para 6.096€. Isto mostra que restringir a árvore reduz sobreajustamento, embora também reduza a capacidade de captar padrões locais complexos.

Os modelos auxiliares da **Tabela 15** devem ser lidos com um objetivo diferente dos modelos preditivos principais, o papel não é substituir o ranking de RMSE, mas verificar se os problemas dos modelos lineares, em especial a heterocedasticidade, podem ser mitigados por transformações, ponderação ou métodos robustos.

Entre estas especificações, a transformação sqrt(price) combinada com transformações log1p dos preditores assimétricos foi a que apresentou melhor comportamento nos diagnósticos. A regressão linear transformada, o Weighted Least Squares, o HuberRegressor, o RANSACRegressor e o QuantileRegressor mediano passaram a apresentar p-values de Breusch-Pagan acima de 0,05 nesta amostra, o que sugere homocedasticidade aceitável no diagnóstico. Contudo, o ganho é sobretudo metodológico: os RMSE destes modelos continuam próximos dos modelos lineares, entre cerca de 55€ e 57€, e não alcançam os modelos não lineares.

O Weighted Least Squares confirma que ponderar observações com maior variância esperada estabiliza parcialmente a leitura residual, mas não melhora a previsão face ao melhor OLS transformado. Os modelos robustos, como Huber, RANSAC e QuantileRegressor, reduzem a sensibilidade a observações extremas e melhoram o diagnóstico de variância, mas também não superam Random Forest nem HistGradientBoosting. Por isso, estes modelos são úteis para interpretação cautelosa e validação dos pressupostos, mas não alteram a escolha final do HistGradientBoosting como modelo académico recomendado.

Os erros-padrão robustos HC3 têm ainda outro papel: corrigem a inferência sobre os coeficientes perante heterocedasticidade, mas não alteram as previsões nem removem por si só a heterocedasticidade dos resíduos. Assim, HC3 deve ser entendido como correção inferencial, enquanto as transformações, WLS e regressões robustas são as tentativas efetivas de correção operacional dos modelos lineares.

Modelo	RMSE treino	RMSE CV	RMSE teste	MAE teste	MedAE	MAPE	WAPE	R ² teste	MaxAE
M0: Baseline –média da amostra do preço	604	63,97	65,53	45,49	34,78	62,4%	41,1%	0	464,22
M: reg. Linear múltipla raw y	53,12	53,24	55,29	36,22	27,4	37,9%	32,8%	0,29	433,39
M2: reg. linear múltipla alvo: log(y)	54	54,07	55,99	34,16	22,51	31,4%	30,9%	0,27	437,4
M3: reg: Polinomial grau 2 log(y)	52,45	53,05	55,07	33,49	21,93	30,7%	30,3%	0,29	461,22
M4 — Interações grau 2 log(y)	52,69	53,25	55,34	33,56	21,57	30,7%	30,3%	0,29	459,73
M5 — Ridge log(y)	54	54,07	55,99	34,16	22,5	31,4%	30,9%	0,27	437,4

M6 — Lasso log(y)	54	54,07	56	34,16	22,47	31,4%	30,9%	0,27	437,45
M7 — Elastic Net log(y)	54	54,07	56	34,16	22,49	31,4%	30,9%	0,27	437,41
M8a — Random Forest log(y)	22,16	49,06	50	29,42	17,92	27,1%	26,6%	0,42	447,7
M8b — Random Forest regularizado log(y)	45,5	50,12	51,6	30,51	19,05	27,7%	27,6%	0,38	451,03
M9 — HistGradientBoosting log(y)	37,32	49,67	50,43	29,86	18,3	27,2%	27%	0,41	444,84
M10 — SVR RBF log(y)	49,31	52,62	54,17	32,26	20,22	28,8%	29,2%	0,32	466,71

Tabela 7 - Comparação dos modelos em treino, validação cruzada e teste

A Figura 6 - Comparação de RMSE em treino, validação cruzada e teste. Figura 6 mostra o compromisso entre desempenho e overfitting. Random Forest tem RMSE de treino muito baixo, mas validação e teste muito superiores, sinal de que ajusta-se de forma muito forte à amostra de treino. Ainda assim, a proximidade entre CV e teste sugere que a estimativa fora da amostra é estável. HistGradientBoosting tem RMSE de teste ligeiramente maior, mas menor diferença treino-teste, sendo uma alternativa mais robusta.




Figura 6 - Comparação de RMSE em treino, validação cruzada e teste.

Na Figura 12, o R^2 demonstra que os modelos de árvores explicam melhor a variação do preço do que os modelos lineares, mas mesmo assim, o melhor R^2 fica perto de 0,42, mostrando que mais de metade da variabilidade permanece por explicar.

4.7 LASSO E SELEÇÃO DE VARIÁVEIS

O Lasso otimizado estritamente por RMSE escolheu $\alpha=0,0001$ e manteve todas as variáveis, indicando que, no critério puramente preditivo, mesmo efeitos pequenos contribuem marginalmente. Para estudar seleção de variáveis, foi aplicada a regra 1-SE, escolhendo $\alpha=0.05$. Esta versão mais esparsa manteve apenas três variáveis.

Tabela 4 - Seleção de variáveis pelo Lasso 1-SE.

Variáveis mantidas no Lasso 1-SE	room_type_Private room, log_minimum_nights, reviews_per_month
Variáveis removidas no Lasso 1-SE	number_of_reviews_ltm, calculated_host_listings_count, number_of_reviews, availability_rate, license_exists, has_reviews, professional, room_type_Shared room, room_type_Hotel room, location_cluster_1, location_cluster_2
RMSE teste Lasso 1-SE	57.447
MAE teste Lasso 1-SE	34.849
R^2 teste Lasso 1-SE	0.231

O Lasso 1-SE retém room_type_Private room, log_minimum_nights e reviews_per_month. Esta seleção reforça uma conclusão substantiva: o tipo de alojamento e a política de estadia mínima são sinais essenciais. Contudo, a perda de desempenho face ao Lasso otimizado por RMSE mostra que a simplicidade do modelo tem custo preditivo, o Lasso é mais útil como ferramenta de interpretação e seleção do que como modelo final de previsão neste dataset.

$$\text{Modelo: } \widehat{price}_i = \exp(\widehat{\beta}_0 - 0.9261 \cdot PrivateRoom_i - 0.1978 \cdot \ln(minimum_nights_i) - 0.0499 \cdot reviews_per_month_i)$$

Variável	Coefficiente	Interpretação aproximada
log_minimum_nights	-0.1978	Um aumento de 1% em minimum_nights está associado a cerca de -0.198% de variação no preço.
reviews_per_month	-0.0499	Uma unidade adicional está associada a uma variação aproximada de -4.9% no preço.
availability_rate	0.0770	Uma unidade adicional está associada a uma variação aproximada de 8.0% no preço.
calculated_host_listings_count	-0.0008	Uma unidade adicional está associada a uma variação aproximada de -0.1% no preço.
room_type_Private room	-0.9261	Passar de 0 para 1 está associado a uma variação aproximada de -60.4% no preço.

license_exists	0.0295	Passar de 0 para 1 está associado a uma variação aproximada de 3.0% no preço.
----------------	--------	---

Tabela 8 - Interpretação log-log e semi-log de coeficientes selecionados

A Figura 10 mostra que a penalização ótima para previsão não elimina variáveis, mas ordena a sua importância linear. room_type_Private room tem o coeficiente negativo de maior magnitude, seguido por log_minimum_nights. Como os coeficientes estão normalizados e no alvo logarítmico, a comparação é sobretudo relativa.

A versão 1-SE (figura 9) evidencia o ganho de parcimónia: apenas três variáveis ficam com coeficientes não nulos. A leitura é substantivamente clara, mas menos precisa. Esta figura ajuda a separar explicação sintética de desempenho preditivo.

4.8 EXEMPLO DE PREVISÃO: PREVISÃO PARA UM ALOJAMENTO ARTIFICIAL

Para ilustrar a utilização prática dos modelos, foi criado um alojamento artificial com características próximas de um alojamento típico em Valência. Este exemplo não serve para medir erro individual, uma vez que não existe preço real observado, mas permite comparar o comportamento de um modelo clássico e de um modelo não linear perante o mesmo perfil de alojamento.

O perfil considerado corresponde a um Entire home/apt, com estadia mínima de 2 noites, 45 reviews acumuladas, 1,8 reviews por mês, 3 alojamentos geridos pelo anfitrião, disponibilidade anual de 180 dias, 12 reviews no último ano, licença visível e localização aproximada em CIUTAT VELLA (Cluster centro histórico-turístico).

As previsões obtidas são muito próximas: o Lasso estima 130,47€ e o HistGradientBoosting estima 128,09€, uma diferença absoluta de apenas 2,38€. Esta proximidade sugere estabilidade para este perfil específico de alojamento. Ainda assim, esta leitura não deve ser interpretada como validação individual, porque o caso é artificial e não tem preço real observado.

Modelo	RMSE teste	MAE teste	WAPE teste	R ² teste	Preço previsto
M6 — Lasso log(y)	56,00€	34,16€	30,88%	0,270	130,47€
M9 — HistGradientBoosting log(y)	50,43€	29,86€	27,00%	0,408	128,09€

Tabela 9 - Métricas globais dos modelos usados no exemplo aplicado.

A qualidade relativa das previsões deve ser avaliada pelas métricas globais no conjunto de teste (Tabela 10). O modelo clássico, neste caso o Lasso com alvo logarítmico, é mais transparente e permite interpretar a influência das variáveis através dos coeficientes, mas apresenta erro global superior enquanto HistGradientBoosting tem menor RMSE, menor MAE, menor WAPE e maior R² no teste, pelo que oferece maior confiança preditiva global. A vantagem prática do modelo não linear está na sua capacidade de captar relações não lineares e interações; a vantagem do modelo clássico está na interpretabilidade.

A previsão de preços pode ser operacionalmente útil, mas não deve ser usada isoladamente para definir preços finais nem constitui evidência causal; trata-se apenas de uma aplicação das associações aprendidas pelos modelos a um perfil plausível.

4.9 OVERFITTING, ROBUSTEZ E UTILIDADE PRÁTICA

O principal risco de overfitting surge nos modelos baseados em árvores, sobretudo no Random Forest. Este modelo apresenta um RMSE de treino muito inferior ao RMSE de validação cruzada e ao RMSE de teste, o que indica que se ajusta de forma muito forte à amostra de treino. No entanto, como os resultados de validação cruzada e de teste são relativamente próximos, o modelo ainda mantém capacidade razoável de generalização. Assim, a avaliação apenas pelo erro de treino seria enganadora.

A utilidade prática do modelo deve ser interpretada com prudência. Com um WAPE próximo de 27% nos melhores modelos, as previsões são úteis para estimar ordens de grandeza e comparar alojamentos entre si, mas não devem ser usadas isoladamente para definir preços finais. Para uma aplicação operacional de pricing, seriam necessárias variáveis adicionais e validação temporal. Neste contexto, o modelo é mais adequado como ferramenta analítica para identificar fatores associados ao preço.

A leitura conjunta de MAE, MedAE e MaxAE mostra que o erro não está distribuído de forma uniforme. A MedAE é bastante inferior ao MAE, o que indica que muitas previsões têm erro moderado. No entanto, alguns alojamentos difíceis elevam o erro médio e o erro máximo. Estes casos parecem corresponder sobretudo a alojamentos de preço elevado, cujas características específicas não estão suficientemente representadas nas variáveis disponíveis.

A análise dos 20 maiores erros absolutos confirma este padrão. Todos os casos pertencem à categoria Entire home/apt e têm preços reais elevados. O preço real mediano deste grupo é 393€, enquanto a previsão mediana é apenas 130,59€. Além disso, todos estão acima do percentil 95 do preço, e o grupo POBLATS MARITIMS é o mais frequente. Isto sugere que o modelo subestima alojamentos premium, especialmente quando faltam variáveis sobre dimensão, qualidade, vista, amenities, localização microgeográfica e nível de luxo como mostra a **Tabela 14**.

O MAPE e o WAPE também devem ser interpretados com cuidado. O MAPE é aplicável porque todos os preços são positivos, mas pode penalizar demasiado alojamentos baratos, onde pequenos erros absolutos representam percentagens elevadas. Por isso, o WAPE é mais adequado como métrica percentual principal, pois avalia o erro absoluto total em relação ao valor total observado dos preços.

5 CONCLUSÃO

5.1 ESCOLHA DO MODELO

Se o critério for interpretação clássica dos coeficientes, o modelo preferido é o Lasso com $\log(\text{price})$. A sua vantagem não é ter o menor erro, mas permitir leitura percentual aproximada dos coeficientes, estabilização por regularização e discussão de seleção de variáveis. Como os pressupostos não são plenamente cumpridos, esta interpretação deve ser entendida como exploratória e associativa, não como inferência causal forte.

Se o critério for cumprimento dos pressupostos lineares, a escolha recai sobre a regressão linear com $\sqrt{\text{price}}$ e preditores assimétricos transformados por $\log_1 p$. Esta especificação obteve diagnóstico de homocedasticidade mais aceitável do que a regressão logarítmica tradicional, mantendo uma estrutura linear. A desvantagem é que a interpretação dos coeficientes é menos imediata do que em $\log(\text{price})$.

Se o critério for previsão pura, o vencedor é M8 - Random Forest $\log(y)$, com o menor RMSE no teste. Contudo, o seu RMSE de treino muito inferior ao RMSE de teste indica maior risco de sobreajustamento. Por isso, o menor erro isolado não é suficiente para o definir como modelo académico final.

Como compromisso geral, recomenda-se M9 - HistGradientBoosting $\log(y)$. Este modelo fica praticamente empatado com o Random Forest no erro de teste, mas apresenta menor sinal de overfitting. Assim, a decisão final é: Lasso para interpretação, regressão linear transformada para pressupostos, Random Forest para previsão pura e HistGradientBoosting como modelo final equilibrado.

5.2 DISCUSSÃO CRÍTICA

A modelação avançada altera a leitura do trabalho em dois pontos. Primeiro, mostra que a regressão linear múltipla não é suficiente para extrair todo o sinal disponível: Random Forest e HistGradientBoosting reduzem o RMSE de teste de cerca de 56 euros para cerca de 50 euros. Segundo, mostra que o ganho dos modelos não lineares não elimina a limitação estrutural dos dados: o melhor R^2 fica abaixo de 0,42.

A pergunta sobre causalidade permanece crítica. A regressão ajuda a separar associações condicionais, mas não transforma dados observacionais em evidência causal. A importância de `room_type_Private room` não significa que mudar formalmente a categoria de um alojamento causaria uma redução de preço; a categoria resume diferenças reais de privacidade, dimensão e experiência. Do mesmo modo, `reviews_per_month` pode refletir procura, antiguidade, preço competitivo ou rotação. A interpretação correta é associativa e condicional.

As subquestões ficam melhor respondidas com os novos modelos. A transformação logarítmica é justificada pela assimetria; as regularizações mostram que não há ganhos fortes face à linear log quando se mantém estrutura linear; o Lasso 1-SE identifica um núcleo mínimo de variáveis; e os modelos não lineares sugerem a existência de padrões não lineares e interações que os modelos lineares captam apenas parcialmente, embora limitados pela falta de variáveis sobre o imóvel.

5.3 RESPOSTA DIRETA ÀS PERGUNTAS DE INVESTIGAÇÃO

5.3.1 QUAL É O IMPACTO DA LOCALIZAÇÃO NO PREÇO DO ALOJAMENTO?

A localização tem impacto preditivo e acrescenta informação ao modelo, embora não seja o factor dominante. A comparação entre representações geográficas mostra que os bairros reais agregados são mais informativos do que os clusters K-Means: no HistGradientBoosting, a versão com clusters obteve RMSE de teste de cerca de 50,43€, enquanto a versão com bairros agregados reduziu o RMSE para cerca de 49,56€ e aumentou o R^2 para cerca de 0,428. Isto sugere que a geografia urbana de Valência contém sinal económico e turístico relevante. Ainda assim, este resultado deve ser lido como associação espacial: estar numa zona valorizada está associado a preços superiores, mas o modelo não prova que a localização, isoladamente, cause esse preço.

5.3.2 ATÉ QUE PONTO O TIPO DE ALOJAMENTO EXPLICA A VARIAÇÃO DE PREÇO?

O tipo de alojamento é a variável mais relevante entre as disponíveis. A dummy ``room_type_Private room`` surge como a variável mais importante na análise por permutação, aumentando o RMSE em cerca de 18,60€ quando é baralhada. O seu coeficiente nos modelos logarítmicos é fortemente negativo, indicando que quartos privados estão associados a preços claramente inferiores aos alojamentos inteiros (``Entire home/apt``), mantendo constantes as restantes variáveis observadas. Assim, o tipo de alojamento explica uma parte substancial da variação de preço e é o principal sinal interpretativo do estudo.

5.3.3 AS POLÍTICAS DE RESERVA TÊM EFEITO NO PREÇO?

As políticas de reserva estão associadas ao preço, sobretudo através de ``minimum_nights``. A variável ``log_minimum_nights`` aparece entre as mais relevantes, com aumento médio do RMSE de cerca de 7,31€ quando é permutada, e apresenta associação negativa com ``log(price)``: alojamentos com estadias mínimas mais longas tendem a ter preço por noite mais baixo. A disponibilidade anual, representada por ``availability_rate``, também contribui para a previsão, mas com peso mais moderado. Como os dados são observacionais, a conclusão correta é que estas políticas estão associadas ao preço, não que alterá-las causaria automaticamente uma alteração do preço.

5.3.4 A ATIVIDADE PASSADA ESTÁ CORRELACIONADA COM PREÇO?

A atividade passada em reviews tem correlação com o preço, mas essa relação é mais fraca e menos direta do que a do tipo de alojamento, localização ou noites mínimas. ``reviews_per_month`` contribui para o modelo não linear, com aumento médio do RMSE de cerca de 4,32€ quando é permutada, mas a sua correlação simples com ``log(price)`` é fraca e tende a ser negativa. Isto é compatível com a ideia de que alojamentos mais baratos podem ter maior rotação e, por isso, mais reviews, enquanto alojamentos mais caros podem receber reservas menos frequentes. As reviews ajudam a previsão, mas não medem diretamente qualidade nem permitem inferir causalidade.

5.3.5 O PERFIL DO ANFITRIÃO ESTÁ ASSOCIADO A PREÇOS MAIS ALTOS (OFERTA PROFISSIONAL) OU MAIS BAIXOS?

O perfil do anfitrião está associado a preços mais altos, mas de forma secundária face ao tipo de alojamento e à localização. ``calculated_host_listings_count`` aparece como variável relevante na análise por permutação, com aumento médio do RMSE de cerca de 5,77€ quando é baralhada, e a variável ``professional`` tem sinal positivo, embora menos forte. Isto sugere que anfitriões com maior escala de operação tendem a gerir alojamentos com preços superiores ou melhor posicionados no mercado. Contudo, esta associação pode refletir factores omitidos, como qualidade do imóvel, zona, capacidade e estratégia comercial, pelo que não deve ser interpretada como efeito causal puro.

5.4 LIMITAÇÕES METODOLÓGICAS

A primeira limitação é a seleção de variáveis imposta pelo ficheiro `listings.csv` resumido. A literatura de preços hedónicos sugere que dimensão, capacidade, número de quartos, casas de banho, qualidade das fotografias, amenities e avaliações detalhadas são determinantes centrais do preço. Como estas variáveis não existem no ficheiro usado, os modelos têm de trabalhar com proxies imperfeitas, como reviews, disponibilidade e tipo de alojamento.

A segunda limitação é temporal. O dataset é essencialmente um snapshot e não permite distinguir sazonalidade, eventos locais, alterações regulatórias ou estratégias dinâmicas de preço. Um alojamento pode ter preço diferente em função da época do ano, do dia da semana ou de eventos específicos em Valência. Como essa informação não está disponível, o modelo estima apenas uma relação média no momento observado.

A terceira limitação é que a avaliação se baseia numa divisão treino/teste aleatória estratificada por quantis de preço. Esta opção é adequada para comparar modelos numa amostra cross-sectional, mas não substitui validação temporal nem validação em snapshots futuros. Para uso operacional, o modelo deveria ser testado em dados posteriores.

5.5 PROPOSTAS DE MELHORIA FUTURA

A melhoria prioritária seria usar o ficheiro listings.csv.gz completo, com variáveis como accomodates, bedrooms, bathrooms, beds, amenities, property_type e review_scores_rating. A inclusão destas variáveis permitiria aproximar melhor a teoria hedónica do preço e reduzir a dependência de proxies.

Outra melhoria seria criar features espaciais mais substantivas: distância ao centro histórico, distância à praia, proximidade a estações de transporte, densidade turística do bairro e indicadores de zona regulada. Estas variáveis poderiam melhorar a interpretação dos efeitos de localização e reduzir a opacidade dos clusters K-Means.

Finalmente, seria útil comparar modelos com validação temporal e técnicas explicativas adicionais, como partial dependence plots ou SHAP values, especialmente para modelos não lineares. Isso permitiria explicar melhor como o preço previsto muda com noites mínimas, reviews, disponibilidade e tipo de alojamento.

5.6 DEPLOYMENT

Num contexto aplicado, o modelo poderia ser usado por anfitriões para comparar o seu alojamento com unidades semelhantes, por investidores para triagem inicial de oportunidades e por investigadores ou entidades públicas para estudar padrões de preço no alojamento local. O uso recomendado é exploratório e comparativo, não automático.

A utilização prática exigiria uma rotina de atualização com novos snapshots, monitorização de erro por zona e tipo de alojamento, validação temporal e revisão periódica das variáveis. Também seria necessário comunicar incerteza, pois previsões pontuais podem ser particularmente frágeis em alojamentos premium ou atípicos.

O modelo não deve ser usado isoladamente para definir preços finais. A decisão de preço deve combinar previsão estatística, conhecimento local, sazonalidade, eventos, qualidade do imóvel, fotografias, amenities, concorrência direta e objetivos do anfitrião.

5.7 CONCLUSÃO FINAL

O estudo mostra que os modelos não lineares melhoram a previsão dos preços face aos modelos lineares, mas que o ganho é limitado pela falta de variáveis estruturais do alojamento. O Random Forest apresenta o melhor desempenho puro no teste, enquanto o HistGradientBoosting é recomendado como modelo final por oferecer um compromisso mais equilibrado entre erro preditivo e risco de sobreajustamento.

Para interpretação, a regressão logarítmica, o Lasso e a importância por permutação indicam que o tipo de alojamento, as noites mínimas, a atividade em reviews, a disponibilidade e o perfil do anfitrião são os sinais mais relevantes. A validação dos pressupostos mostrou ainda que a heterocedasticidade dos modelos lineares não deve ser apenas reportada: foi parcialmente ou de forma aceitável corrigida através de transformações $\log_1 p$ dos preditores assimétricos, $\sqrt{\text{price}}$, WLS e regressões robustas. Ainda assim, a interpretação dos coeficientes logarítmicos deve manter-se cautelosa e acompanhada por erros-padrão robustos HC3.

Ainda assim, os resultados devem ser lidos como associações condicionais e não como efeitos causais. A principal limitação do desempenho não está apenas no algoritmo utilizado, mas também na ausência de variáveis como número de quartos, capacidade, comodidades, qualidade das fotografias, distância a pontos turísticos e indicadores de reputação detalhada.

6 BIBLIOGRAFIA

- Airbnb, I. (2025). Obtido de Insider Airbnb: <https://insideairbnb.com/get-the-data/>
- Airdna. (2025). *Airdna*. Obtido de <https://www.airdna.co/vacation-rental-data/app/es/valencia/valencia/overview>
- España, G. d. (24 de 12 de 2024). *Agéncial estatal boletín oficial del Estado*. Obtido de boe: https://www.boe.es/diario_boe/txt.php?id=BOE-A-2024-26931
- UE. (29 de 04 de 2025). *europa*. Obtido de Euro-Lex: <https://eur-lex.europa.eu/legal-content/EN/LSU/?uri=CELEX%3A32024R1028>
- València, A. d. (11 de 02 de 2026). *La Fundació Visit València presenta FOCUS, una evolució de su sistema de inteligencia turística enfocada a los retos actuales del turismo*. Obtido de Valencia: <https://www.valencia.es/cas/actualidad/-/content/visit-val%C3%A8ncia-presenta-foco-una-herramienta-de-medici%C3%B3n-tur%C3%ADstica>
- Lancaster, K. J. (1966). A new approach to consumer theory. *Journal of Political Economy*, 74(2), 132–157. <https://doi.org/10.1086/259131>
- Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1), 34–55. <https://doi.org/10.1086/260169>
- Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical statistics for data scientists* (2nd ed.). O'Reilly.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55-67.
- Lancaster, K. J. (1966). A new approach to consumer theory. *Journal of Political Economy*, 74(2), 132-157. <https://doi.org/10.1086/259131>
- Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1), 34-55. <https://doi.org/10.1086/260169>
- Tibshirani, R. (1996). Regression shrinkage and selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267-288.
- Zou, H., & Hastie, T. (2005). Regularization and variable selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301-320.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

	number_of_reviews_ltm	number_of_reviews	minimum_nights	calculated_host_listings_count
N	7844	7844	7844	7844
Média	13,353	51,636	6,554	12,325
Desvio padrão	17,752	86,94	18,756	20,771
min	0	0	1	1
25%	1	3	1	1
50%	6	16	2	3
75%	21	58,25	5	11
max	367	935	366	103
amplitude	367	935	365	102
IQR	20	55,25	4	10
assimetria	2,868	3,038	13,279	2,504
curtose	25,877	11,98	228,086	5,893

Tabela 10 - Estatísticas completas das variáveis quantitativas contínuas

	latitude	longitude	price	reviews_per_month	availability_365
N	7844	7844	6979	6867	7844
Média	39,467	-0,364	164,113	1,695	185,951
std	0,019	0,023	732,639	1,666	120,086
min	39,28	-0,426	8	0,01	0
25%	39,461	-0,38	71	0,47	77
50%	39,469	-0,371	102	1,17	179

75%	39,475	-0,344	140	2,49	305
max	39,546	-0,276	40000	37,71	365
amplitude	0,266	0,15	39992	37,7	365
IQR	0,013	0,036	69	2,02	228
assimetria	-4,843	0,372	29,441	3,414	-0,056
curtose	38,527	-0,568	1328,501	44,759	-1,42

Tabela 11 – Estatísticas completas das variáveis quantitativas contínuas

Variável	N	Cardinalidade	Moda	Frequência da moda	Frequência relativa da moda (%)
neighbourhood_group	7844	19	POBLATS MARITIMS	1471	18,753
neighbourhood	7844	85	CABANYAL-CANYAMELAR	750	9,561
host_name	7838	1764	Marta	124	1,582
room_type	7844	4	Entire home/apt	5782	73,712

Tabela 12 - Estatísticas completas das variáveis qualitativas




Figura 7 - Escolha do número de clusters geográficos




Figura 8 - Os clusters representados num mapa geográfico da zona




Figura 9 - QQplot dos modelos de regressão regularizado

Modelo	Tipo	Linearidade	Homocedasticidade	Normalidade	Multicolinearidade	Overfitting
M1 — Linear múltipla raw y	linear	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M2 — Linear múltipla log(y)	linear	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M3 — Polinomial grau 2 log(y)	polinomial	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M4 — Interações grau 2 log(y)	interações	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M5 — Ridge log(y)	regularizado	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M6 — Lasso log(y)	regularizado	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M7 — Elastic Net log(y)	regularizado	Cumpre	Não cumpre	Parcialmente	Cumpre	Cumpre
M8 — Random Forest log(y)	árvore	Não aplicável	Não aplicável	Não aplicável	Não aplicável	Não cumpre
M8b — Random Forest regularizado log(y)	árvore	Não aplicável	Não aplicável	Não aplicável	Não aplicável	Parcialmente
M9 — HistGradientBoosting log(y)	boosting	Não aplicável	Não aplicável	Não aplicável	Não aplicável	Parcialmente
M10 — SVR RBF log(y)	SVR	Não aplicável	Não aplicável	Não aplicável	Não aplicável	Cumpre
RANSACRegressor — Regressão robusta (sqrt(price))	linear corrigido	Parcialmente	Cumpre	Parcialmente	Cumpre	Cumpre
HuberRegressor — Regressão robusta (sqrt(price))	linear corrigido	Parcialmente	Cumpre	Parcialmente	Cumpre	Cumpre
QuantileRegressor_mediana — Regressão robusta (sqrt(price))	linear corrigido	Parcialmente	Cumpre	Parcialmente	Cumpre	Cumpre
Regressão linear — OLS transformado (sqrt(price))	linear corrigido	Cumpre	Cumpre	Parcialmente	Cumpre	Cumpre
Regressão linear ponderada — Weighted Least Squares (sqrt(price))	linear corrigido	Cumpre	Cumpre	Parcialmente	Cumpre	Cumpre
Regressão linear — OLS transformado (price)	linear corrigido	Cumpre	Cumpre	Parcialmente	Cumpre	Cumpre

Tabela 13 - Pressupostos da regressão

Indicador	Valor
Erro absoluto máximo	444.842
Preço real mediano top 20 erros	393
Preço previsto mediano top 20 erros	130.593
N top 20 Entire home/apt	20
N top 20 Private room	0
N top 20 sem reviews	1
N top 20 preço real acima P95	20
Bairro/grupo mais frequente no top 20	POBLATS MARITIMS

Tabela 14- Caracterização dos 20 maiores erros absolutos no modelo final.




Figura 10 - Coeficientes do Lasso otimizado por RMSE.




Figura 11 - Coeficientes do Lasso 1-SE.

Modelo / especificação	Transformação	Método	RMSE	MAE	R ²	WAPE	Decisão	Variáveis usadas
RANSACRegressor	sqrt(price)	Regressão robusta	56,10	33,54	0,267	30,33%	Corrigida de forma aceitável	X_logfeat
HuberRegressor	sqrt(price)	Regressão robusta	56,39	33,46	0,259	30,25%	Corrigida de forma aceitável	X_logfeat

QuantileRegressor _mediana	sqrt(price)	Regressão robusta	56,82	33,39	0,248	30,19%	Corrigida de forma aceitável	X_logfeat
Regressão linear	sqrt(price)	OLS transform ado	55,33	34,36	0,287	31,07%	Corrigida de forma aceitável	X_logfeat
Regressão linear com HC3	sqrt(price)	Erros- padrão robustos HC3	55,33	34,36	0,287	31,07%	Corrigida de forma aceitável	X_logfeat
Regressão linear ponderada	sqrt(price)	Weighted Least Squares	55,37	34,41	0,286	31,12%	Corrigida de forma aceitável	X_logfeat
Regressão linear	price	OLS transform ado	55,20	35,75	0,290	32,33%	Corrigida de forma aceitável	Conjunto base
Regressão linear	price	OLS transform ado	55,27	36,19	0,288	32,73%	Não corrigida	Conjunto base
Regressão linear	sqrt(price)	OLS transform ado	55,37	34,77	0,286	31,44%	Parcialment e mitigada	Conjunto base
Regressão linear	log1p(pric e)	OLS transform ado	55,93	33,81	0,271	30,57%	Parcialment e mitigada	X_logfeat
Regressão linear	log(price)	OLS transform ado	55,95	33,81	0,271	30,57%	Parcialment e mitigada	X_logfeat
Regressão linear	log1p(pric e)	OLS transform ado	55,98	34,16	0,270	30,89%	Parcialment e mitigada	Conjunto base
Regressão linear	log(price)	OLS transform ado	55,99	34,16	0,270	30,88%	Parcialment e mitigada	Conjunto base

Tabela 15 – modelos auxiliares




Figura 12 - Comparação de RMSE em treino, validação cruzada e teste